

# Leveraging Data Science in Market Research



הצגה לקבוצת:

יוני 2020

### נתחיל בסיפור אישי

אפשר לומר שנולדתי לתוך התעשיה של מחקרי שוק

ההורים שלי הקימו מכון מחקר בשנות ה-90...

כילד – הייתי מבלה במעבדות המחקר של אוניברסיטת חיפה

Pen and Paper כנער – הייתי עוזר במשרד בהדפסה (או גריסה) של שאלוני כמתבגר (עתודאי) – הלכתי ללמוד מתמטיקה עם סטטיסטיקה וחקר ביצועים

(ואז תואר שני בחקר ביצועים, ואז תואר שלישי)



ובסוף יצא (כמה לא מפתיע) שאני עוסק ב-Data Science ושותף במכון מחקר אבל – מספיק לדבר עלי. בואו נדבר עליכם, ועל Data Science (ולמה זה צריך לעניין אתכם)

### מהם האתגרים המשמעותיים ביותר של תעשיית מחקרי השוק? (רשימה חלקית)

(רשימה חלקית)

שיטות

- הרבה שיטות מקבילות (כלים רבים, קשה להתמחות ולהתעדכן)
  - שיעורי היענות נמוכים

לקוחות

- מצפים לתובנות אתמול בבוקר (עלול לבוא על חשבון האיכות)
- עיתים גם על חשבון איכות) תקציבים רוצים הרבה במעט (מובילים לפתרונות DIY לעיתים גם על חשבון איכות)
  - י מתקשים לנסח את הרצונות שלהם (והרצונות משתנים ללא הרף)

### מהם האתגרים המשמעותיים ביותר של תעשיית מחקרי השוק? (רשימה חלקית)

#### תוצאות

- Actionable insights קשה להפוך אותם
- עסקים רצים מהר וקשה להדביק את הקצב (תוצאות עשויות להיות לא רלוונטיות)
   טכנולוגיות וחדשנות
- (אבל לא באמת מבינים מה זה אומר) Al או Data Science מו Buzz words לקוחות מושפעים מ
  - להציג בידול, להביא דברים חדשים, להמציא מחדש

#### ועוד ועוד...

עד סוף המפגש נענה על:

1. איך ובמה Data Science נותן מענה

2. איך אתם יכולים להפעיל Data Scientists בשביל לקבל את המענה



# ?Data Science אז מה זה בעצם

אין באמת תשובה, זה איפשהו בין... סטטיסטיקה, מדעי המחשב (תכנות, מחקר, ועוד...)

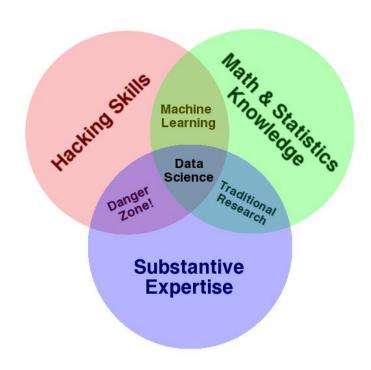


Figure 1a: Conway's Data Scientist Venn Diagram

### ככה נראה "יום העבודה" של Data Scientist

אולי יראה מוכר, כי זה בעצם לא מאוד רחוק מהעבודה של חוקר שוק... (אבל עם טוויסט)





### אבל באיזה כלים?

ניסוי מחשבתי. באילו כלים **אתם** משתמשים?

https://app.sarid-ins.com/s3/mr-tools

#### תוצאות

הנה מה שאני משתמש בו, לפי תדירות (לפעמים זה יותר מזכיר פיתוח תוכנה מאשר מחקר שוק): github <- Python/R -> פלטפורמה לסקרים/מאגרי מידע -> מצגות -> כונן משותף -> וורד, אקסל

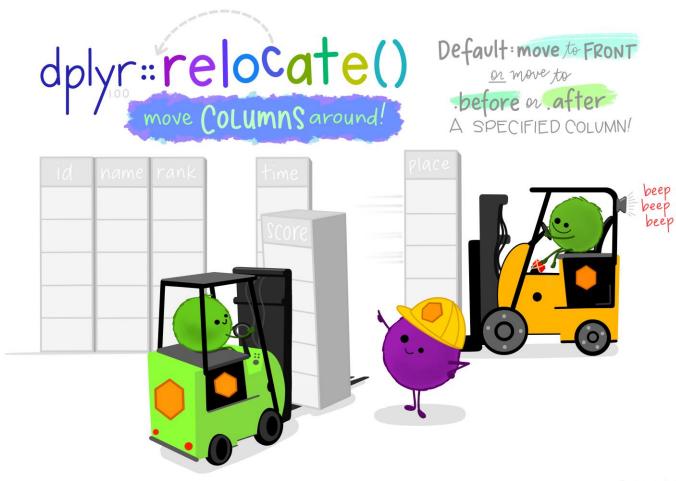
מה זה אומר? שהעבודה היום-יומית שלי היא איפשהו באמצע בין מחקר לבין פיתוח

מחבר נתונים מהרבה מקורות



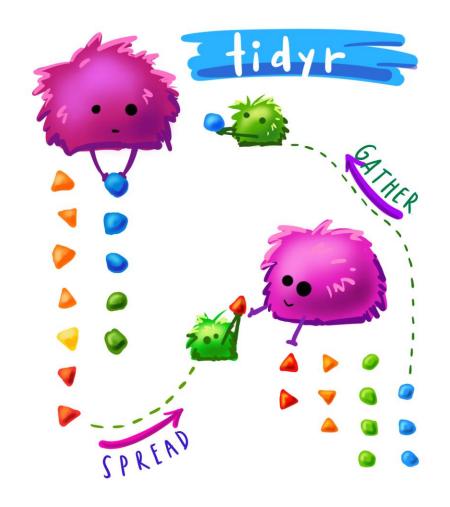


#### מסדר את הנתונים





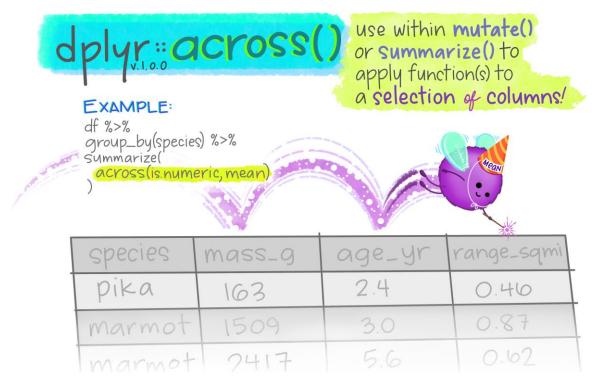
מסאג' לנתונים



בונה משתנים



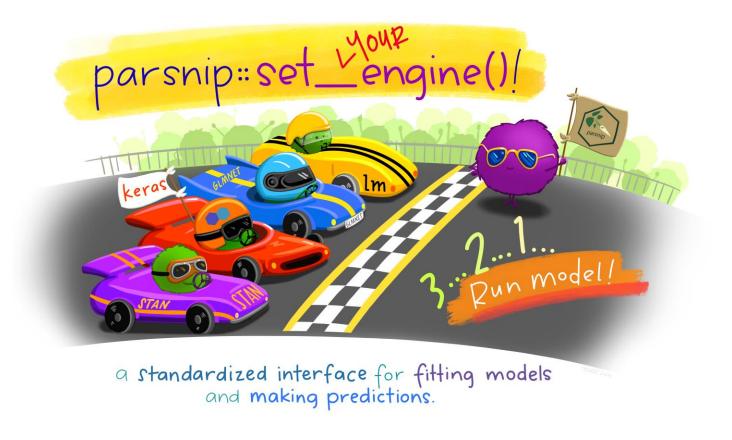
#### עושה טרנספורמציות



#### ויז׳ואליזציות



#### בונה מודלים



מציג הכל באמצעות.... דוחות (ועוד – מיד נדגים)





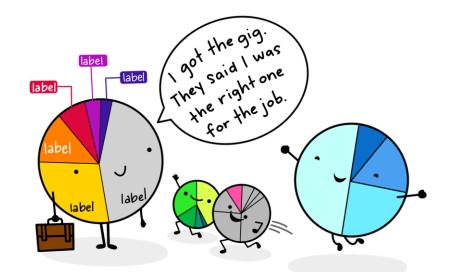
### קצת סדר...

עד כה התייחסנו ל-Data Scientists

יש גם בעלי תפקידים נוספים, שלפעמים מבלבלים אותם:



- Data analyst
  - BI •
  - ועוד...





### ?Data Scientist מה הרקע של

- רקע אקדמי •
- בדרך כלל תואר שני או שלישי •
- מקצוע אנליטי (סטטיסטיקה, מתמטיקה, מדעי המחשב, יכול להיות גם פיזיקה, או מקצועות הנדסיים)
  - ניסיון נדרש •
  - כדי ש-Data Scientist יצליח לשתף פעולה על פרויקט רצוי ניסיון של 5 שנים לפחות בתחום שקשור ל-Domain (או הנחיה מקצועית של חוקר בכיר יותר)
    - כלים
    - יהולך ונעלם: SPSS ,SAS, הולך ונעלם: Python או Python, הולך ונעלם: SPSS ,SAS)
      - כלים נוספים כתלות בעסק ובאופן הפעילות



## מתי לשלב Data Scientist בפרויקט?

"החל מניתוח נתונים פשוט של סקרים

יבוא לידי ביטוי כאשר: Data Scientists היתרון הגדול של

- י מקורות נתונים מרובים שצריך לחבר ביניהם
  - עבודת סידור נתונים משמעותית
- מודלים מורכבים (Conjoint, מודלי חיזוי)
- כשרוצים להבטיח שקיפות (Transparency), ויכולת שחזור בעתיד (Reproducibility)
  - כשרוצים אוטומציות (תהליכים שקורים הרבה, שיחזרו עליהם בעתיד)
    - Production כשצריך לשלב את התובנות או המודלים במערכות •

# מה התוצרים שניתן לדרוש?

סט היכולות של Data Scientist מאפשר לו להפיק כמעט כל דבר



למה? כי כשעובדים עם כלים כמו R ו-Python כל הכלים כבר קיימים בצורת חבילות, רק צריך לדעת למצוא אותם

חשוב של-Data Scientist תהיה יכולת להבין את הכלים, המגבלות שלהם, ולהתאים אותם למצב הרלוונטי (כאן הרקע האקדמי נכנס לעניין)

### ממה להיזהר?

- ״לסבך את העניינים Data Scientists − ל-Data Scientists (במיוחד מתחילים)
  - צריך להקפיד על התאמת הרמה לקהל היעד: •
- למקבלי החלטות עם קשב נמוך, ועומס קוגניטיבי פשטות, על חשבון
   העמקה
  - למקבלי החלטות אנליטיים, כמותיים אפשר להעמיק למודלים ומשמעויות, להיכנס לפרטים



### דוגמאות מגניבות מהשנים האחרונות...

# דוגמה 1: ניתוח תוכן הערות מילוליות

- הערות מילוליות מאוד נפוצות בסקרים, וגם באפיקי תקשורת נוספים מול הלקוח (Social, Product reviews)
- י ״השיטה הקלאסית״ במחקרי שוק היא לעבור על ההערות ולסווג אותן לקטגוריות. לוקח הרבה זמן, לא Scalable.
- בפועל באלגוריתמים של Data Science ניתן לחשב Sentiment, לבחון קשרים, לחלץ מוטיבים אוטומטית ולתת למקבלי
   החלטות כלים נוספים לחקור את ההערות, מעבר ל"קובץ אקסל" או תרשים סטטי



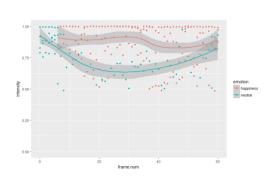


### דוגמה 2: ניתוח הבעות פנים בוידאו

איך מודדים אפקטיביות של פרסומת במדיה (לפני שידור)? בשיטות הקלאסיות – צפיה ודיווח עצמי (מענה על שאלות)

כלים כיום מאפשרים לנתח הבעות פנים (יש מספר חברות שמציעות את הטכנולוגיה "כמוצר שלם")

#### https://sarid.shinyapps.io/MR faceR/



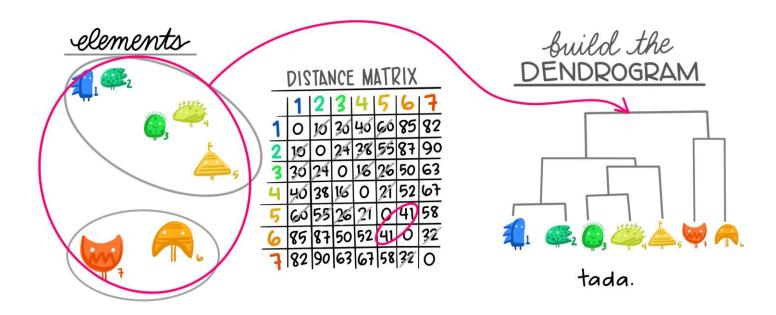
(שמחה, כעס, Facial coding וסיווג לרגשות שמחה, כעס, נייטרלי, פחד, גועל,...).



# דוגמה 3: Clustering

סגמנטציה באמצעות Clustering – סיווג לקוחות לקבוצות על בסיס פרמטרים שנאספו (בסקרים או בDatabase).

מאפשר למקבלי החלטות להגדיר טרמינולוגיה, להתמקד בקבוצות מסוימות, ולהכווין אסטרטגיה





## דוגמה 4: אוטומציה, יצירת דוחות ב-Batch

בממשקי Point and click (אקסל, SPSS) קשה לייצר מסה של דוחות לעומת זאת...

כשכותבים את הדוח בקידוד, המאמץ דומה 1000  $pprox 100 \approx 10$  pprox 1... תוצר יכול להיות מאות מצגות, מאות מסמכים, או דשבורד מפולחים לפי תתי-אוכלוסיות, מחלקות, או כל חלוקה ארגונית אחרת רלוונטית



### דוגמה 5: ניתוח מרחבי, אופטימיזציה של מיקום מרכזי שירות

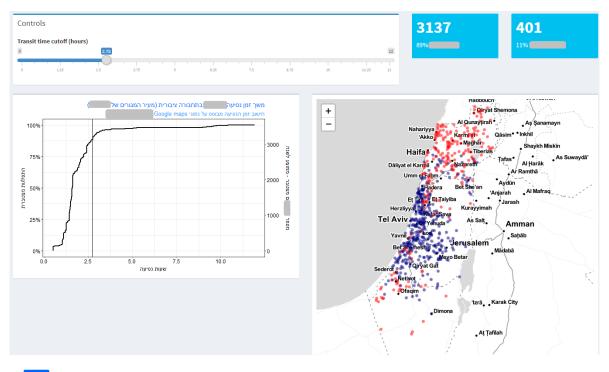
אינטגרציה של מקורות מידע פנימיים וגלויים מאפשרים לבחון פריסה מרחבית של שירותים שונים

מחד – מקום מגורים של הלקוח

מאידך – מודל לחישוב מיקום אופטימלי של מרכזי השירות (מקסום הסבירות לרכישה למול עלויות)

מרחקי נסיעה – מחושבים באמצעות API של google maps

מקבלי החלטות – מקבלים אפליקציה לבחינת Cutoff שונים, מיקום מרכזים שונים והמשמעויות שלהם על הרווחים



### והרשימה ממשיכה...

וניתוח תוכן Web scraping

חיזוי מכירה

חיזוי נטישה

Time Series Analysis

ועוד...

# איך מתניעים פרויקט Data Science? צ'ק ליסט

מרימים את הטלפון ומתקשרים אלי (סתתתםם...)

#### :בריך לכלול Data Scientist אריך לכלול

- 1. מטרות הפרויקט, היכרות עם עולם התוכן של הלקוח, Context כללי
- 2. מחקרים שנעשו בעבר בהקשר של הפרויקט הנוכחי, נתוני עבר (האם נדרשות השוואות? היכן נמצאים מאגרי נתונים קודמים)
- 3. מידע על אופן איסוף הנתונים בפרויקט (סקר? דאטה פנימי? ריבוי מקורות? בעיות, מגבלות)
  - 4. ולידציות שנכנסו בפנים (לדוגמה ולידציות בסקרים על משך מענה, שאלות מלכודת)
    - 5. תוצרים רלוונטיים נדרשים, שאלות מחקר, לוחות זמנים

שיחות שוטפות עם ה-Data Scientist, להיות מעורבים, לבקש ללמוד, לשאול הרבה שאלות, להכיר לו את עולם התוכן.



### לקריאה נוספת

- https://www.sarid-ins.co.il/blog הבלוג של מכון שריד
  - <u>adisarid.github.io</u> (קצת יותר טכני)
    - The Rstudio blog •
- (אם אתם מעוניינים ללמוד R פנו אלי, קורסים מעת לעת) •



Thanks!

Adi Sarid adi@sarid-ins.co.il

@SaridResearch

https://www.sarid-ins.co.il